Phân loại thể loại âm nhạc sử dụng đặc trưng âm thanh và mạng nơ-ron truyền thẳng trên GTZAN

Hoàng Gia Phát Đỗ Thanh Sơn

Tháng 10 năm 2026

Tóm tắt

Báo cáo trình bày quy trình phân loại thể loại âm nhạc dựa trên các đặc trưng được trích xuất từ tín hiệu âm thanh và mạng nơ-ron truyền thẳng nhiều lớp (Multilayer Perceptron – MLP). Bộ dữ liệu GTZAN gồm 1.000 đoạn nhạc thuộc 10 thể loại, mỗi đoạn dài khoảng 30 giây. Âm thanh được chia thành các đoạn ngắn 3 giây để phục vụ trích xuất và tổng hợp đặc trưng.

Các đặc trưng được sử dụng mô tả năng lượng, sự biến thiên của tín hiệu, phân bố tần số, cao độ và âm sắc. Sau bước tiền xử lý, mỗi đoạn nhạc được biểu diễn bằng một vector đặc trưng có kích thước cố định để đưa vào MLP. Quy trình gồm chuẩn bị dữ liệu, xây dựng mô hình, huấn luyện và đánh giá bằng các chỉ số phân loại.

Kết quả đánh giá được trình bày với độ chính xác validation 84,45% ở epoch 300 và các chỉ số precision, recall, F1-score trên 2.997 mẫu. Báo cáo đồng thời phân tích ưu điểm, hạn chế của phương pháp dựa trên đặc trưng thống kê và những lưu ý khi chia dữ liệu thành nhiều đoạn ngắn.

Từ khóa: GTZAN, xử lý tín hiệu âm thanh, trích xuất đặc trưng, MFCC, MLP, phân loại thể loại âm nhạc.

Mục lục

Tóm tắt **i**

1 Giới thiệu bài toán **1**
1.1 Bối cảnh và mục tiêu . . . 1
1.2 Bộ dữ liệu GTZAN . . . 1
1.3 Hướng tiếp cận . . . 3

2 Cơ sở xử lý tín hiệu âm thanh **4**
2.1 Biểu diễn tín hiệu và tốc độ lấy mẫu . . . 4
2.1.1 Biểu đồ sóng . . . 4
2.1.2 Tốc độ lấy mẫu và giới hạn Nyquist . . . 5
2.2 Biểu đồ phổ thời gian–tần số . . . 6
2.3 Các đặc trưng năng lượng và miền thời gian . . . 6
2.3.1 Giá trị hiệu dụng RMS . . . 6
2.3.2 Tỷ lệ đổi dấu ZCR . . . 7
2.4 Các đặc trưng miền tần số . . . 7
2.4.1 Spectral roll-off . . . 7
2.4.2 Spectral centroid . . . 8
2.4.3 Spectral bandwidth . . . 9
2.5 Các đặc trưng cao độ và âm sắc . . . 10
2.5.1 Chroma . . . 10
2.5.2 Phân tách thành phần hòa âm và bộ gõ . . . 10
2.5.3 Hệ số MFCC . . . 10
2.6 Tổng hợp đặc trưng theo đoạn nhạc . . . 12

3 Phương pháp thực hiện **13**
3.1 Quy trình tổng quát . . . 13
3.2 Phân đoạn và tổ chức dữ liệu . . . 13
3.2.1 Chia đoạn nhạc . . . 13
3.2.2 Trích xuất và lưu trữ đặc trưng . . . 13
3.2.3 Chia tập dữ liệu và chuẩn hóa . . . 14
3.3 Kiến trúc mạng nơ-ron truyền thẳng . . . 15
3.3.1 Mô hình tổng quát . . . 15
3.3.2 Cấu hình mô hình . . . 16

3.4 Softmax và hàm mất mát 16
3.5 Huấn luyện và đánh giá 17

4 Kết quả và thảo luận **18**
4.1 Kết quả huấn luyện 18
4.2 Các chỉ số phân loại 18
4.3 Ma trận nhầm lẫn 19
4.4 Thảo luận và hạn chế 20
4.4.1 Sự phụ thuộc giữa các đoạn nhạc 20
4.4.2 Số lượng mẫu đánh giá 20
4.4.3 Giới hạn của đặc trưng thống kê 20
4.4.4 Hướng cải tiến 20
4.5 Kết luận 20

Danh mục hình

1.1 Minh họa bộ dữ liệu GTZAN 2

2.1 Biểu đồ sóng của một đoạn nhạc 4
2.2 Biểu diễn tín hiệu tại các tần số lấy mẫu khác nhau 5
2.3 So sánh biểu đồ phổ tại hai tần số lấy mẫu 6
2.4 Giá trị RMS theo thời gian của tín hiệu âm thanh 7
2.5 Tỷ lệ đổi dấu của tín hiệu theo từng khung 8
2.6 Minh họa spectral roll-off với ngưỡng 85% 8
2.7 Minh họa trọng tâm phổ của đoạn nhạc 9
2.8 Độ phân tán phổ của tín hiệu theo thời gian 9
2.9 Biểu diễn chroma của tín hiệu âm nhạc 10
2.10 Thành phần harmonic và percussive sau phân tách HPSS 11
2.11 Biểu diễn các hệ số MFCC theo thời gian 11

3.1 Minh họa quá trình chia một bản nhạc thành các đoạn 3 giây 14
3.2 Ví dụ bảng dữ liệu đặc trưng âm thanh được lưu dưới dạng CSV 14
3.3 Sơ đồ phân loại âm nhạc từ vector đặc trưng đến nhãn thể loại 15

4.1 Ma trận nhầm lẫn của mô hình MLP 19

Danh mục bảng

1.1 Thông tin tổng quan về bộ dữ liệu GTZAN 2

3.1 Kiến trúc mạng MLP dùng cho bài toán phân loại 16
3.2 Cấu hình huấn luyện mô hình MLP 17

4.1 Kết quả đánh giá phân loại trên 10 lớp âm nhạc 18

Chương 1

Giới thiệu bài toán

1.1 Bối cảnh và mục tiêu

Thể loại âm nhạc là một thuộc tính quan trọng trong việc tổ chức kho nhạc, hỗ trợ tìm kiếm và xây dựng hệ thống gợi ý nội dung. Khi số lượng bản thu ngày càng lớn, quá trình phân loại thủ công trở nên tốn thời gian và khó đảm bảo tính nhất quán. Vì vậy, bài toán phân loại thể loại âm nhạc tự động được đặt ra nhằm xác định nhãn thể loại phù hợp từ nội dung tín hiệu âm thanh.

Tín hiệu âm thanh số được biểu diễn dưới dạng chuỗi mẫu theo thời gian. Tuy nhiên, các giá trị biên độ riêng lẻ chưa thể phản ánh đầy đủ đặc trưng của một thể loại nhạc. Do đó, phương pháp thực hiện tập trung trích xuất những đại lượng mô tả năng lượng, phân bố tần số, cao độ, âm sắc và sự biến thiên của tín hiệu. Các đại lượng này được tổng hợp thành vector đầu vào cho mạng nơ-ron nhân tạo.

Mục tiêu của đề tài là xây dựng quy trình phân loại từ dữ liệu âm thanh đến nhãn dự đoán, gồm các bước tiền xử lý, trích xuất đặc trưng, huấn luyện và đánh giá mô hình. Mô hình được lựa chọn là mạng nơ-ron truyền thẳng nhiều lớp (Multilayer Perceptron – MLP), nhận vector đặc trưng thay vì nhận trực tiếp ảnh phổ như mạng CNN.

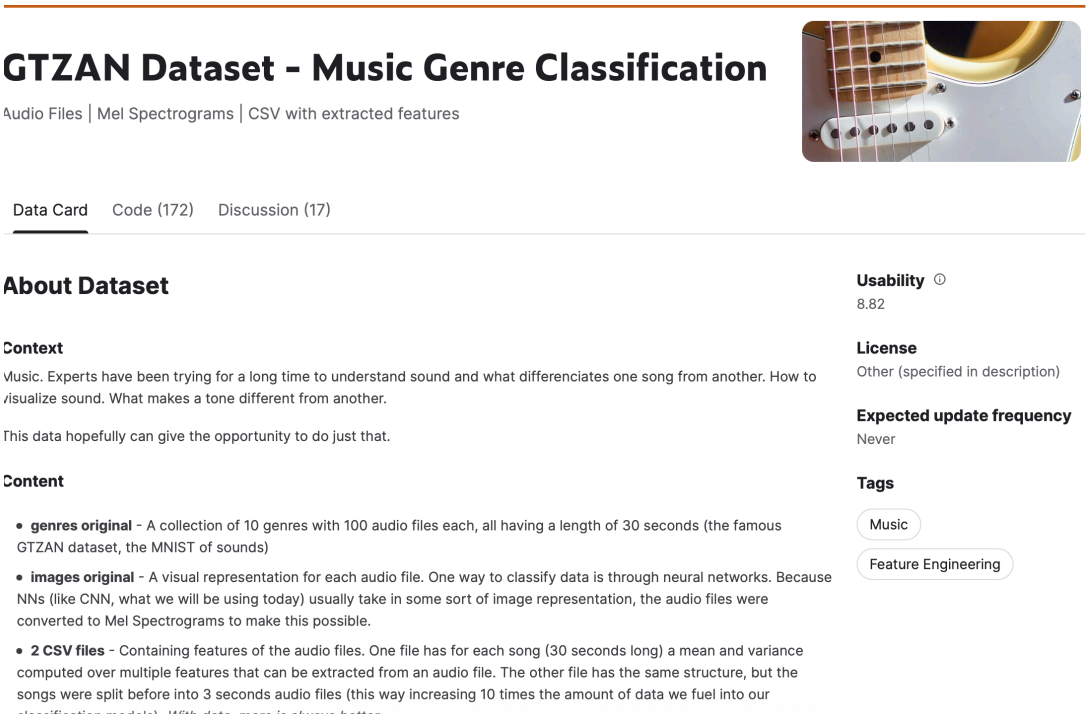
1.2 Bộ dữ liệu GTZAN

Bộ dữ liệu GTZAN gồm 1.000 đoạn âm thanh, được chia thành 10 thể loại: blues, classical, country, disco, hiphop, jazz, metal, pop, reggae và rock. Mỗi thể loại có 100 đoạn nhạc, thời lượng mỗi đoạn khoảng 30 giây. Đây là bài toán phân loại có giám sát, trong đó mỗi đoạn nhạc được gắn một nhãn thể loại xác định.

Để tăng số đơn vị dữ liệu phục vụ trích xuất đặc trưng, mỗi đoạn nhạc 30 giây được chia thành các đoạn ngắn 3 giây không chồng lấn. Với điều kiện mọi đoạn đều được xử lý đầy đủ, từ 1.000 đoạn nhạc gốc có thể tạo ra 10.000 đoạn ngắn. Mỗi đoạn ngắn kế thừa nhãn của bản thu ban đầu.

Bảng 1.1: Thông tin tổng quan về bộ dữ liệu GTZAN

Thuộc tính	**Mô tả**
Bộ dữ liệu	GTZAN
Số đoạn nhạc gốc	1.000
Số thể loại	10
Số đoạn nhạc mỗi thể loại	100
Thời lượng đoạn gốc	Khoảng 30 giây
Thời lượng đoạn sau phân chia	3 giây
Số đoạn ngắn tối đa dự kiến	10.000
Dữ liệu đầu vào mô hình	Vector đặc trưng âm thanh



Hình 1.1: Minh họa bộ dữ liệu GTZAN

1.3 Hướng tiếp cận

Quá trình phân loại được thực hiện theo bốn giai đoạn chính: chuẩn bị và phân đoạn tín hiệu âm thanh, trích xuất đặc trưng, xây dựng mạng MLP và đánh giá kết quả dự đoán. Các đặc trưng được tổng hợp theo từng đoạn ngắn để tạo đầu vào có số chiều cố định cho mô hình.

Hướng tiếp cận này giúp giảm kích thước dữ liệu đầu vào so với việc sử dụng toàn bộ các mẫu âm thanh hoặc ảnh phổ. Đồng thời, từng nhóm đặc trưng có ý nghĩa rõ ràng trong xử lý tín hiệu, tạo thuận lợi cho việc phân tích và giải thích kết quả phân loại.

Chương 2

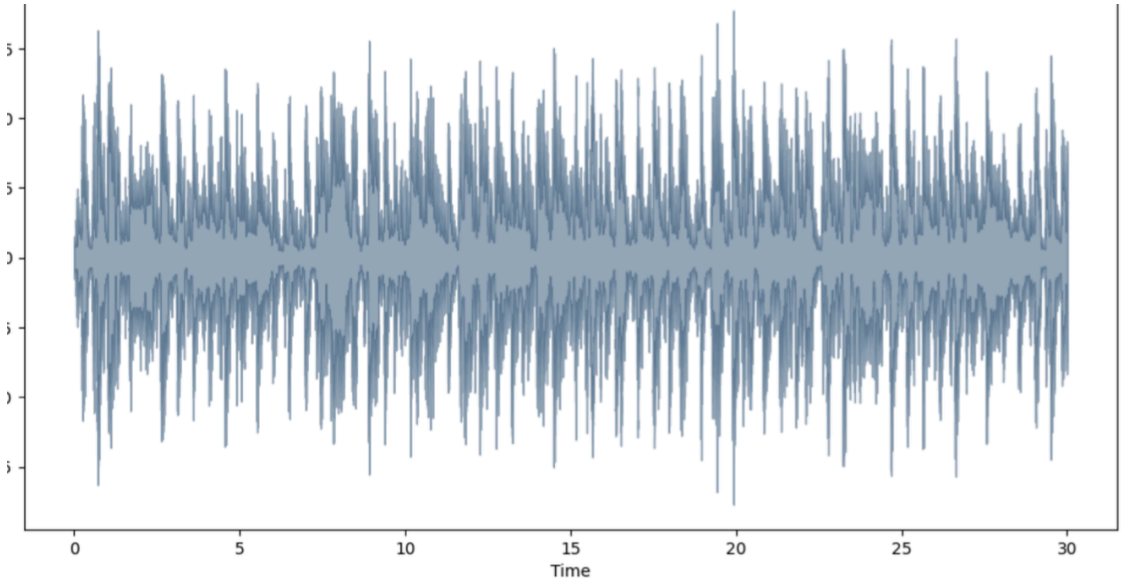
Cơ sở xử lý tín hiệu âm thanh

2.1 Biểu diễn tín hiệu và tốc độ lấy mẫu

2.1.1 Biểu đồ sóng

Biểu đồ sóng (waveform) biểu diễn sự thay đổi biên độ của tín hiệu âm thanh theo thời gian. Trục hoành thể hiện thời gian, còn trục tung biểu diễn giá trị biên độ tại các thời điểm lấy mẫu. Thông qua waveform, có thể quan sát được những khoảng lặng, sự biến đổi cường độ tín hiệu và các sự kiện âm thanh diễn ra trong thời gian ngắn.

Cần phân biệt biên độ với độ lớn âm thanh cảm nhận. Độ lớn mà người nghe cảm nhận còn phụ thuộc vào tần số và đặc điểm của hệ thính giác; do đó, chỉ một giá trị biên độ chưa đủ để mô tả hoàn toàn mức âm thanh.



Hình 2.1: Biểu đồ sóng của một đoạn nhạc

2.1.2 Tốc độ lấy mẫu và giới hạn Nyquist

Âm thanh trong thực tế là tín hiệu liên tục theo thời gian. Để máy tính có thể lưu trữ và xử lý, tín hiệu được lấy mẫu thành dãy rời rạc theo biểu thức:

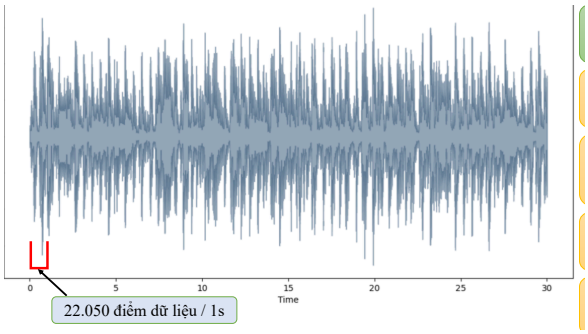
$$x[n] = x_c\left(\frac{n}{f_s}\right), \tag{2.1}$$

trong đó $x_c(t)$ là tín hiệu liên tục, $x[n]$ là dãy mẫu rời rạc và f_s là tần số lấy mẫu, có đơn vị Hz. Chẳng hạn, với $f_s = 22\,050$ Hz, mỗi giây âm thanh có 22.050 mẫu; một đoạn 3 giây chứa 66.150 mẫu khi không thay đổi độ dài tín hiệu.

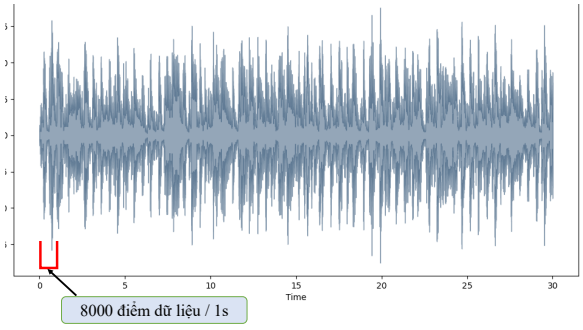
Theo định lý lấy mẫu Nyquist–Shannon, đối với tín hiệu giới hạn băng và đáp ứng các điều kiện tái tạo lý tưởng, tần số lấy mẫu cần lớn hơn hai lần tần số cao nhất của tín hiệu:

$$f_s > 2f_{\max}. \tag{2.2}$$

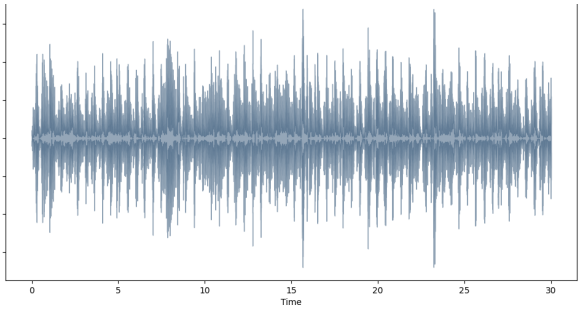
Tần số $f_s/2$ được gọi là tần số Nyquist. Khi giảm tần số lấy mẫu, các thành phần vượt quá giới hạn Nyquist mới phải được lọc trước khi giảm mẫu để tránh hiện tượng chồng phổ (aliasing). Vì vậy, tần số lấy mẫu quyết định giới hạn tần số cao nhất có thể biểu diễn chính xác, chứ không chỉ quyết định số lượng mẫu trong một giây.



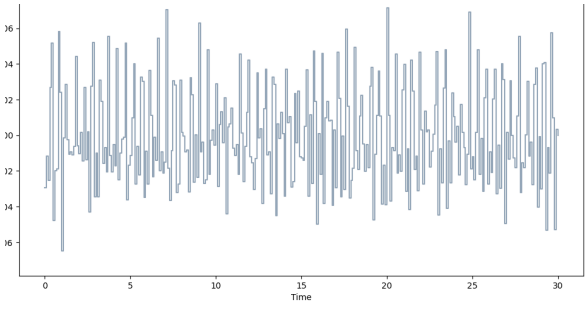
(a) 22.050 Hz



(b) 8.000 Hz



(c) 1.000 Hz



(d) 10 Hz

Hình 2.2: Biểu diễn tín hiệu tại các tần số lấy mẫu khác nhau

2.2 Biểu đồ phổ thời gian–tần số

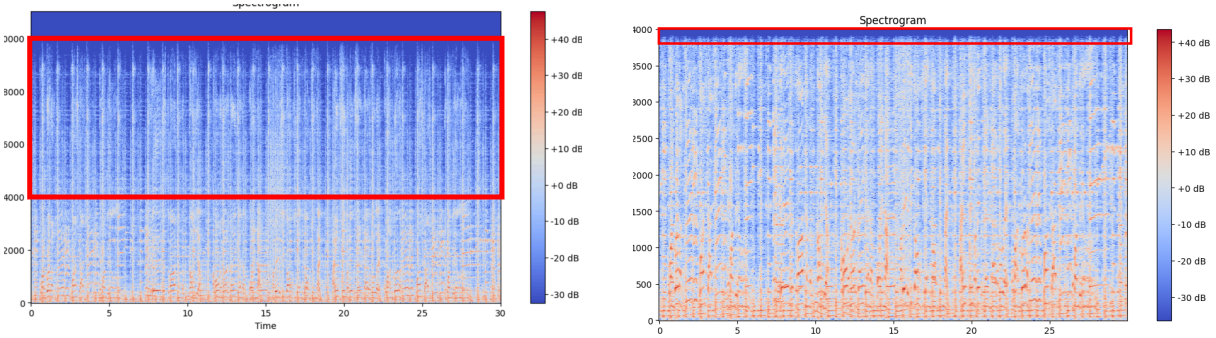
Spectrogram là biểu diễn thể hiện các thành phần tần số của tín hiệu thay đổi theo thời gian. Trục ngang biểu diễn thời gian, trục dọc biểu diễn tần số, còn màu sắc tại mỗi vị trí cho biết độ mạnh tương đối của thành phần phổ tương ứng, thường được thể hiện trên thang decibel (dB).

Một phương pháp phổ biến để xây dựng spectrogram là biến đổi Fourier thời gian ngắn (Short-Time Fourier Transform – STFT). Tín hiệu được chia thành các khung ngắn, áp dụng hàm cửa sổ rồi tính biến đổi Fourier cho từng khung:

$$X(m,k) = \sum_{n=0}^{N-1} x[n+mH]w[n] \exp\left(-j\frac{2\pi kn}{N}\right), \tag{2.3}$$

trong đó N là số mẫu của một khung, H là bước dịch khung, $w[n]$ là hàm cửa sổ, m là chỉ số khung và k là chỉ số tần số. Từ kết quả STFT, có thể xây dựng phổ biên độ $|X(m,k)|$ hoặc phổ công suất $|X(m,k)|^2$. Các giá trị này thường được chuyển sang thang logarit để dễ quan sát.

Waveform giúp theo dõi biên độ theo thời gian, trong khi spectrogram cho biết năng lượng hoặc độ lớn phổ tập trung tại những vùng tần số nào ở từng thời điểm. Những đường gần nằm ngang thường liên quan đến các thành phần tần số được duy trì, còn những vệt gần thẳng đứng thường cho thấy sự kiện âm thanh biến đổi nhanh.



(a) Tần số lấy mẫu 22.050 Hz **(b)** Tần số lấy mẫu 8.000 Hz

Hình 2.3: So sánh biểu đồ phổ tại hai tần số lấy mẫu

Với $f_s = 22\,050$ Hz, phổ một phía có thể biểu diễn đến tần số Nyquist 11.025 Hz. Nếu tín hiệu được lấy mẫu lại đúng cách ở 8.000 Hz, giới hạn này giảm còn 4.000 Hz; các thành phần cao hơn phải được loại bỏ trước khi giảm mẫu.

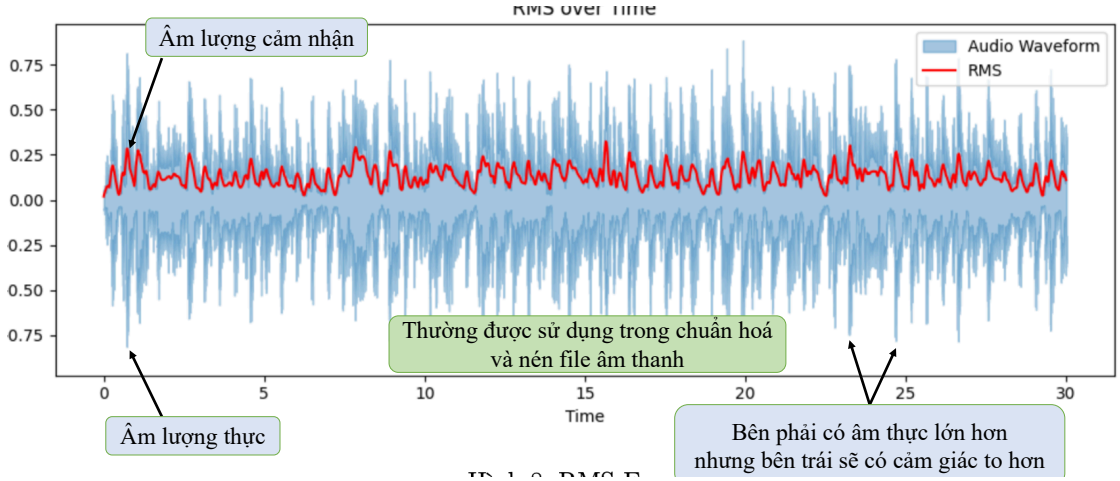
2.3 Các đặc trưng năng lượng và miền thời gian

2.3.1 Giá trị hiệu dụng RMS

RMS (Root Mean Square) mô tả biên độ hiệu dụng của tín hiệu trong một khung thời gian. Công thức tính RMS là:

$$\mathrm{RMS}(m) = \sqrt{\frac{1}{N}\sum_{n=0}^{N-1} x_m[n]^2}, \tag{2.4}$$

trong đó $x_m[n]$ là mẫu thứ n của khung thứ m, còn N là số mẫu trong khung. RMS thường được sử dụng để theo dõi sự thay đổi mức tín hiệu, nhận biết những khoảng có năng lượng mạnh hoặc yếu và mô tả động học của âm thanh.



Hình 2.4: Giá trị RMS theo thời gian của tín hiệu âm thanh

2.3.2 Tỷ lệ đổi dấu ZCR

Zero-Crossing Rate (ZCR) là tỷ lệ số lần tín hiệu đổi dấu trong một khung. Khi quy ước xử lý mẫu bằng không được thống nhất, ZCR có thể được tính theo:

$$\mathrm{ZCR}(m) = \frac{1}{2(N-1)}\sum_{n=1}^{N-1} \left|\mathrm{sgn}(x_m[n]) - \mathrm{sgn}(x_m[n-1])\right|. \tag{2.5}$$

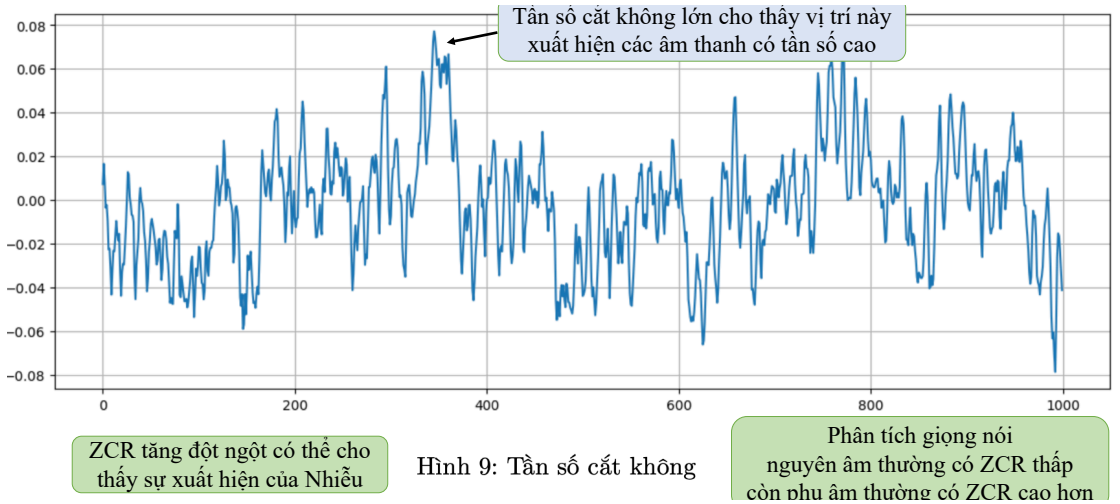
Giá trị ZCR cao thường xuất hiện khi tín hiệu thay đổi dấu nhanh, chẳng hạn trong một số âm thanh có nhiều thành phần tần số cao hoặc thành phần nhiễu. Tuy nhiên, ZCR không phải là phép đo trực tiếp tần số cơ bản của âm thanh phức hợp.

2.4 Các đặc trưng miền tần số

2.4.1 Spectral roll-off

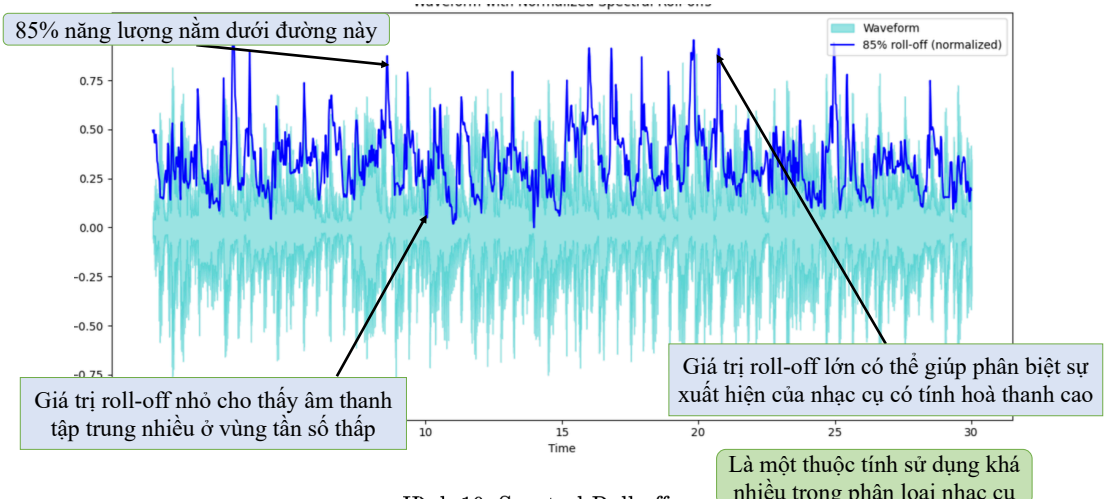
Spectral roll-off là tần số mà phần năng lượng phổ tích lũy từ các tần số thấp đến vị trí đó đạt một tỷ lệ nhất định của tổng năng lượng phổ. Với phổ công suất $P_m[k]$ và ngưỡng $\rho = 0{,}85$, chỉ số k_r được xác định là chỉ số nhỏ nhất thỏa mãn:

$$\sum_{k=0}^{k_r} P_m[k] \geq \rho \sum_{k} P_m[k]. \tag{2.6}$$



Hình 2.5: Tỷ lệ đổi dấu của tín hiệu theo từng khung

Tần số tương ứng f_{k_r} là spectral roll-off. Chỉ số này giúp mô tả mức độ tập trung phổ tại các vùng tần số thấp và cao. Giá trị roll-off lớn thường cho thấy phân bố phổ trải rộng hơn về phía tần số cao.



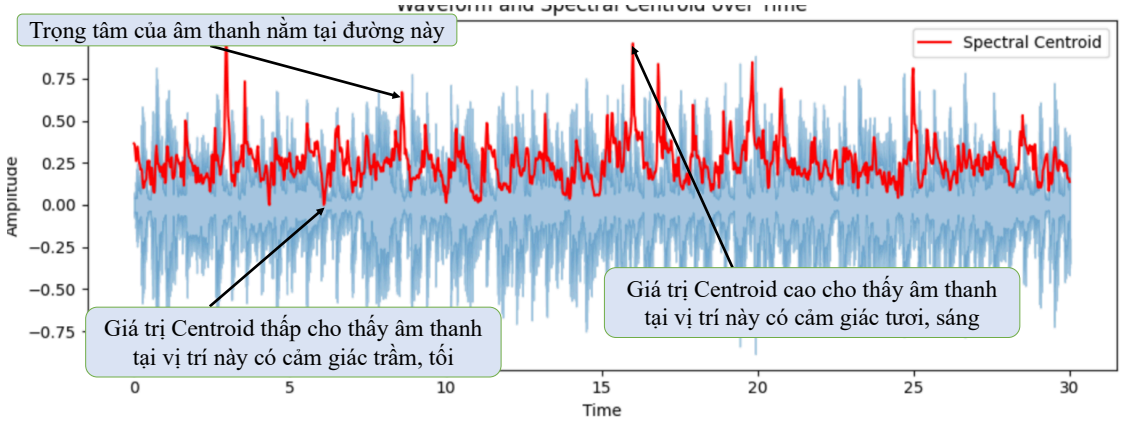
Hình 2.6: Minh họa spectral roll-off với ngưỡng 85%

2.4.2 Spectral centroid

Spectral centroid là trọng tâm tần số của phổ biên độ, được tính như trung bình có trọng số của các tần số:

$$C_m = \frac{\sum_k f_k A_m[k]}{\sum_k A_m[k]}, \qquad A_m[k] = |X(m,k)|. \tag{2.7}$$

Trong đó f_k là tần số của bin thứ k. Spectral centroid cao thường liên quan đến âm sắc sáng; giá trị thấp thường xuất hiện khi phổ tập trung nhiều hơn ở các tần số thấp. Các khung có tổng biên độ phổ bằng không cần được xử lý riêng để tránh chia cho không.



Hình 11: Spectral Centroid

Cho thấy được độ "tươi"/ "sáng" của âm thanh

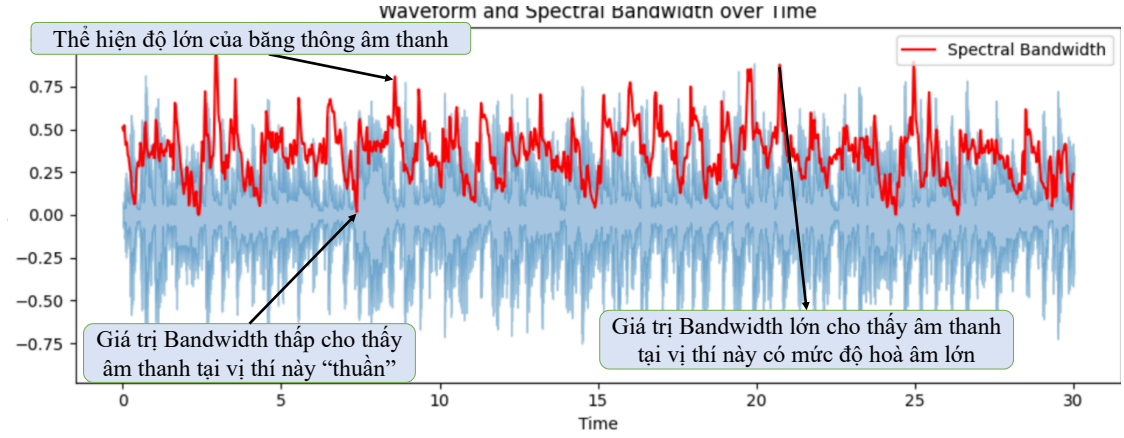
Hình 2.7: Minh họa trọng tâm phổ của đoạn nhạc

2.4.3 Spectral bandwidth

Spectral bandwidth biểu diễn độ phân tán của phổ quanh spectral centroid. Với bandwidth bậc hai, công thức có dạng:

$$B_m = \sqrt{\frac{\sum_k (f_k - C_m)^2 A_m[k]}{\sum_k A_m[k]}}. \tag{2.8}$$

Bandwidth nhỏ cho thấy phổ tập trung gần trọng tâm, trong khi bandwidth lớn cho thấy mức phân tán rộng hơn. Đặc trưng này hỗ trợ mô tả sự khác biệt về âm sắc và độ rộng phổ giữa các đoạn nhạc.



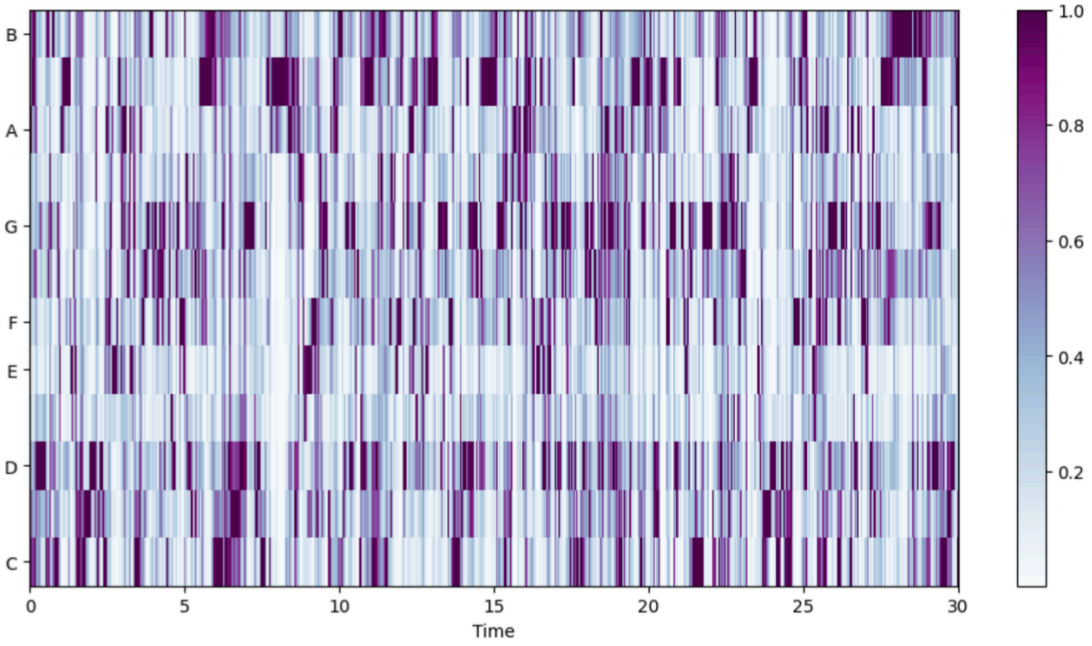
Hình 12: Spectral Bandwidth

Hình 2.8: Độ phân tán phổ của tín hiệu theo thời gian

2.5 Các đặc trưng cao độ và âm sắc

2.5.1 Chroma

Chroma biểu diễn sự phân bố năng lượng theo 12 lớp cao độ trong hệ âm nhạc phương Tây. Những nốt cách nhau một hoặc nhiều quãng tám được gộp về cùng một lớp cao độ. Nhờ đó, chroma giúp mô tả cấu trúc hòa âm và đặc điểm hợp âm của đoạn nhạc, đồng thời bổ sung thông tin cho các đặc trưng năng lượng và phổ.



Hình 2.9: Biểu diễn chroma của tín hiệu âm nhạc

2.5.2 Phân tách thành phần hòa âm và bộ gõ

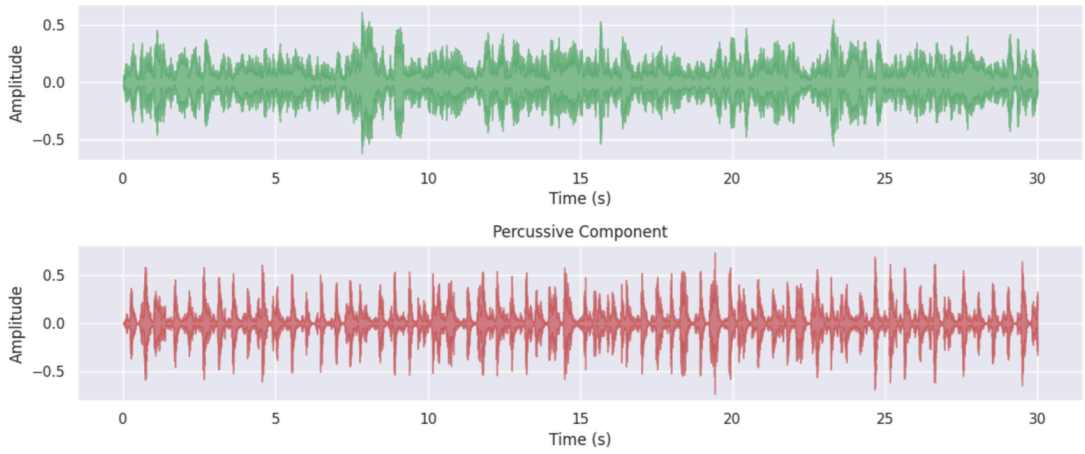
Harmonic/Percussive Source Separation (HPSS) phân tách tín hiệu theo đặc điểm biến đổi trong miền thời gian–tần số. Thành phần harmonic thường chứa các cấu trúc duy trì theo thời gian; thành phần percussive thường gắn với những biến đổi ngắn và mạnh. Có thể mô tả gần đúng:

$$x[n] \approx x_h[n] + x_p[n], \tag{2.9}$$

trong đó $x_h[n]$ và $x_p[n]$ lần lượt là thành phần harmonic và percussive. HPSS không nhất thiết tách chính xác từng nhạc cụ, nhưng giúp phân tích riêng một số đặc trưng của hòa âm và tiết tấu.

2.5.3 Hệ số MFCC

Mel-Frequency Cepstral Coefficients (MFCC) là tập hệ số đặc trưng dùng để mô tả hình dạng phổ và âm sắc theo thang tần số Mel. Quy trình tính MFCC thường gồm: tính



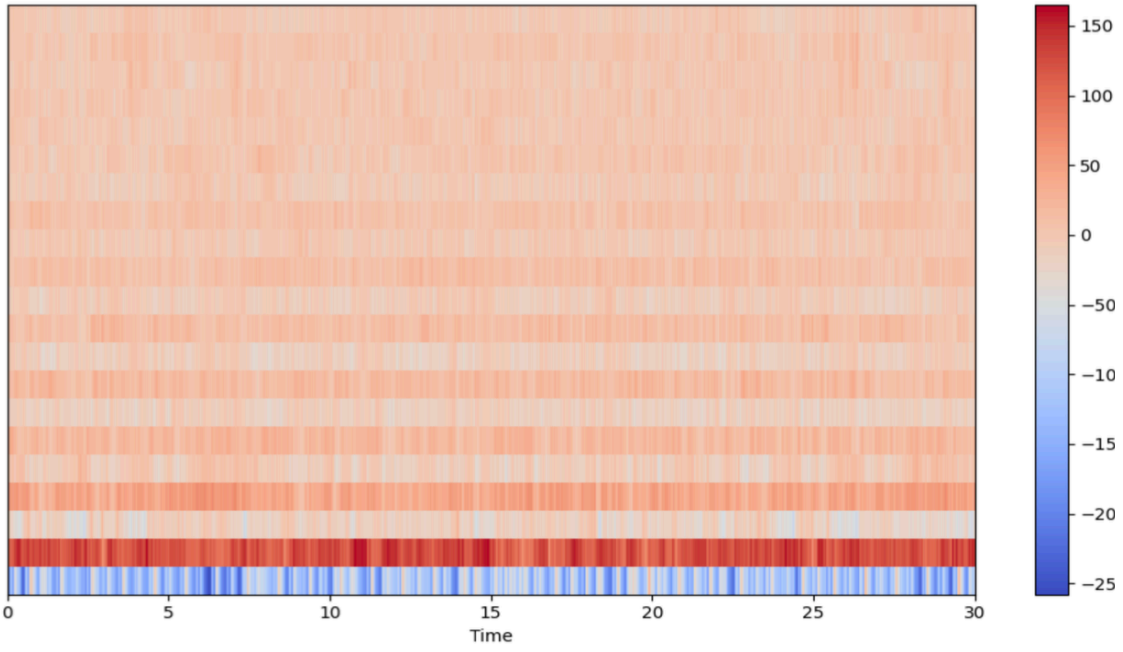
Hình 2.10: Thành phần harmonic và percussive sau phân tách HPSS

phổ công suất, áp dụng các bộ lọc Mel, lấy logarit năng lượng và biến đổi cosine rời rạc (DCT).

Nếu $E_m[b]$ là năng lượng tại bộ lọc Mel thứ b, một công thức biểu diễn hệ số MFCC thứ q là:

$$c_m[q] = \sum_{b=0}^{B-1} \log(E_m[b] + \varepsilon) \cos\left[\frac{\pi q}{B}\left(b + \frac{1}{2}\right)\right], \tag{2.10}$$

trong đó B là số bộ lọc Mel, còn $\varepsilon > 0$ giúp tránh lấy logarit của 0. Hệ số chuẩn hóa có thể thay đổi tùy quy ước DCT được sử dụng. MFCC phù hợp để mô tả đặc điểm âm sắc, nhưng không tự biểu diễn đầy đủ nhịp điệu hoặc cấu trúc dài hạn của bản nhạc.



Hình 2.11: Biểu diễn các hệ số MFCC theo thời gian

2.6 Tổng hợp đặc trưng theo đoạn nhạc

Mỗi đặc trưng có thể được tính trên nhiều khung thời gian của cùng một đoạn nhạc. Để tạo vector có kích thước cố định cho MLP, ta sử dụng các đại lượng thống kê như trung bình và phương sai. Với một dãy giá trị đặc trưng $a_1, a_2, \ldots, a_T$:

$$\mu_a = \frac{1}{T}\sum_{t=1}^{T} a_t, \qquad \sigma_a^2 = \frac{1}{T}\sum_{t=1}^{T}(a_t - \mu_a)^2. \tag{2.11}$$

Sau khi tổng hợp các đại lượng thống kê, mỗi đoạn nhạc được chuyển thành một vector số. Cách biểu diễn này giúp giảm kích thước đầu vào, thuận tiện cho lưu trữ và huấn luyện. Tuy nhiên, việc tính trung bình và phương sai làm mất phần lớn thông tin về thứ tự biến đổi theo thời gian; hai đoạn nhạc có cấu trúc tiết tấu khác nhau vẫn có thể có giá trị thống kê gần giống nhau.

Chương 3

Phương pháp thực hiện

3.1 Quy trình tổng quát

Hệ thống phân loại thể loại âm nhạc gồm bốn giai đoạn: phân đoạn tín hiệu âm thanh, trích xuất và tổng hợp đặc trưng, huấn luyện mạng MLP, sau đó đánh giá chất lượng dự đoán. Đầu vào của mô hình là vector đặc trưng có kích thước cố định thay vì tín hiệu âm thanh thô hoặc ảnh spectrogram.

Việc sử dụng các đặc trưng đã được lựa chọn giúp giảm số chiều đầu vào và chi phí huấn luyện. Tuy nhiên, hiệu quả mô hình phụ thuộc vào khả năng phản ánh thông tin âm nhạc của các đặc trưng được trích xuất.

3.2 Phân đoạn và tổ chức dữ liệu

3.2.1 Chia đoạn nhạc

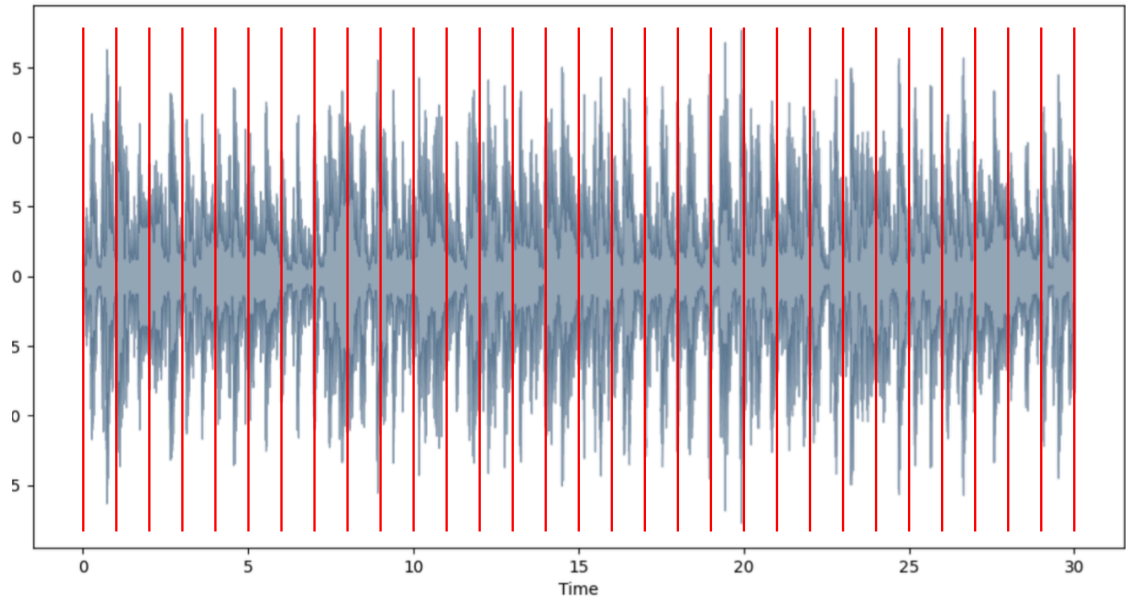
Mỗi bản nhạc có thời lượng khoảng 30 giây được chia thành các đoạn ngắn 3 giây, không chồng lấn. Theo đó, mỗi bản nhạc có thể tạo ra 10 đoạn con; 1.000 bản nhạc tương ứng tối đa 10.000 đoạn ngắn khi mọi tệp đều được xử lý đầy đủ. Các đoạn ngắn được gán nhãn thể loại theo bản thu gốc.

Việc phân đoạn làm tăng số mẫu dùng để học, đồng thời cho phép phân tích các đặc điểm âm thanh theo từng khoảng thời gian nhỏ. Tuy nhiên, các đoạn xuất phát từ cùng một bản nhạc có quan hệ với nhau và không được xem là những bản thu hoàn toàn độc lập.

3.2.2 Trích xuất và lưu trữ đặc trưng

Trên mỗi đoạn âm thanh, các nhóm đặc trưng được tính toán, gồm RMS, ZCR, spectral centroid, spectral bandwidth, spectral roll-off, chroma, MFCC và những đại lượng phù hợp khác. Các giá trị theo khung được tổng hợp bằng trung bình, phương sai để xây dựng vector đặc trưng đầu vào.

Dữ liệu có thể được lưu thành bảng CSV, trong đó mỗi hàng biểu diễn một đoạn



Hình 3.1: Minh họa quá trình chia một bản nhạc thành các đoạn 3 giây

nhạc, mỗi cột là một thuộc tính. Một số tên cột tiêu biểu gồm `filename`, `length`, `chroma_stft_mean`, `chroma_stft_var`, `rms_mean` và `rms_var`. Cột chứa nhãn thể loại được sử dụng làm biến mục tiêu khi huấn luyện.

Số chiều đầu vào thực tế, ký hiệu d, phải được xác định từ số thuộc tính số sau khi loại bỏ các cột nhãn, tên tệp và những trường không được dùng để dự đoán:

$$d = \text{số cột của ma trận đặc trưng đầu vào } X. \tag{3.1}$$

	filename	length	chroma_stft_mean	chroma_stft_var	rms_mean	rms_var	spectral_centroid_mean
0	blues.00000.0.wav	66149	0.335406	0.091048	0.130405	0.003521	1773.065032
1	blues.00000.1.wav	66149	0.343065	0.086147	0.112699	0.001450	1816.693777
2	blues.00000.2.wav	66149	0.346815	0.092243	0.132003	0.004620	1788.539719
3	blues.00000.3.wav	66149	0.363639	0.086856	0.132565	0.002448	1655.289045
4	blues.00000.4.wav	66149	0.335579	0.088129	0.143289	0.001701	1630.656199

Hình 3.2: Ví dụ bảng dữ liệu đặc trưng âm thanh được lưu dưới dạng CSV

3.2.3 Chia tập dữ liệu và chuẩn hóa

Dữ liệu được chia thành các tập huấn luyện, validation và test tùy theo mục đích sử dụng. Để đánh giá công bằng, nên chia theo bản thu gốc, sau đó mới tạo hoặc phân bổ những đoạn 3 giây sao cho tất cả đoạn từ cùng một bản thu chỉ xuất hiện trong một tập dữ liệu. Điều này giúp hạn chế rò rỉ dữ liệu giữa quá trình huấn luyện và đánh giá.

Các đặc trưng có đơn vị và khoảng giá trị khác nhau nên cần được chuẩn hóa trước khi đưa vào mạng MLP. Một cách phổ biến là chuẩn hóa Z-score:

$$\widetilde{x}_j = \frac{x_j - \mu_j}{\sigma_j + \varepsilon}, \tag{3.2}$$

trong đó μ_j và σ_j là trung bình, độ lệch chuẩn của đặc trưng thứ j, còn ε là một số nhỏ để tránh chia cho không. Các tham số chuẩn hóa chỉ được tính từ tập huấn luyện, sau đó áp dụng giữ nguyên cho validation và test.

3.3 Kiến trúc mạng nơ-ron truyền thẳng

3.3.1 Mô hình tổng quát

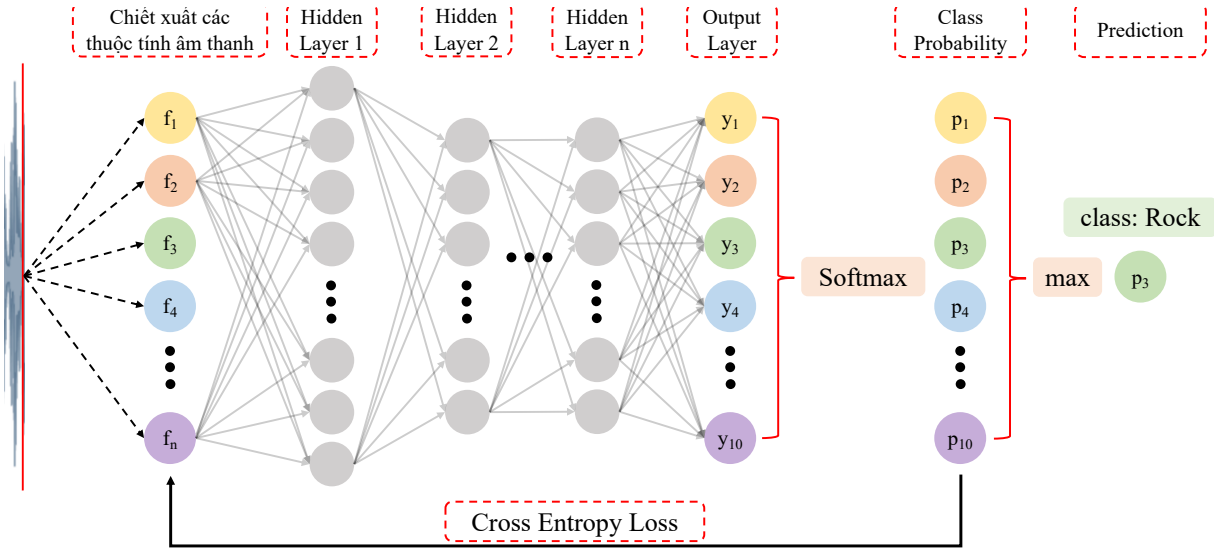
Đầu vào là vector đặc trưng $\mathbf{x} \in \mathbb{R}^d$. Mạng MLP gồm nhiều lớp kết nối đầy đủ (fully connected), trong đó đầu ra của lớp trước trở thành đầu vào của lớp tiếp theo. Tại lớp ẩn thứ l, phép biến đổi được mô tả bởi:

$$\mathbf{h}^{(l)} = \mathrm{ReLU}\left(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}\right), \qquad \mathbf{h}^{(0)} = \mathbf{x}. \tag{3.3}$$

Trong đó, $\mathbf{W}^{(l)}$ là ma trận trọng số, $\mathbf{b}^{(l)}$ là vector bias và $\mathbf{h}^{(l)}$ là đầu ra của lớp ẩn thứ l. Hàm kích hoạt ReLU được định nghĩa là:

$$\mathrm{ReLU}(u) = \max(0, u). \tag{3.4}$$

ReLU giúp mạng học được những quan hệ phi tuyến giữa các đặc trưng âm thanh và nhãn thể loại.



Hình 3.3: Sơ đồ phân loại âm nhạc từ vector đặc trưng đến nhãn thể loại

3.3.2 Cấu hình mô hình

Mạng sử dụng năm lớp ẩn với số nơ-ron lần lượt là 512, 256, 128, 64 và 32. Sau các lớp ẩn là hàm kích hoạt ReLU và Dropout với tỷ lệ 0,2. Lớp cuối có 10 nơ-ron, tương ứng với 10 thể loại nhạc.

Bảng 3.1: Kiến trúc mạng MLP dùng cho bài toán phân loại

Thành phần	Đầu vào	Đầu ra	Xử lý tiếp theo
Linear 1	d	512	ReLU, Dropout(0,2)
Linear 2	512	256	ReLU, Dropout(0,2)
Linear 3	256	128	ReLU, Dropout(0,2)
Linear 4	128	64	ReLU, Dropout(0,2)
Linear 5	64	32	ReLU, Dropout(0,2)
Linear đầu ra	32	10	Logits

Dropout tạm thời vô hiệu hóa ngẫu nhiên một phần giá trị đầu ra trong giai đoạn huấn luyện để hạn chế hiện tượng quá khớp. Khi chuyển sang chế độ đánh giá bằng `model.eval()`, Dropout được tắt.

3.4 Softmax và hàm mất mát

Lớp cuối của MLP tạo ra 10 giá trị logits, ký hiệu $\mathbf{z} = [z_1, z_2, \ldots, z_{10}]$. Để chuyển logits thành xác suất dự đoán cho từng lớp, sử dụng hàm Softmax:

$$p_i = \frac{\exp(z_i)}{\sum_{j=1}^{10} \exp(z_j)}. \tag{3.5}$$

Nhãn dự đoán được xác định từ lớp có giá trị lớn nhất:

$$\widehat{c} = \arg\max_i p_i = \arg\max_i z_i. \tag{3.6}$$

Với nhãn đúng được biểu diễn theo one-hot t_i, hàm mất mát Cross-Entropy trên một mẫu là:

$$\mathcal{L} = -\sum_{i=1}^{10} t_i \ln p_i = -\ln p_c, \tag{3.7}$$

trong đó c là chỉ số lớp đúng. Giá trị loss càng nhỏ thể hiện mô hình phân bố xác suất càng phù hợp với nhãn thực tế.

Khi sử dụng `nn.CrossEntropyLoss` trong PyTorch, đầu vào của hàm mất mát nên là logits trực tiếp vì hàm đã tích hợp phép biến đổi log-softmax. Do đó, không cần áp dụng Softmax trong hàm `forward` trước khi tính loss. Hàm Softmax chỉ được dùng riêng khi cần hiển thị xác suất dự đoán.

3.5 Huấn luyện và đánh giá

Mô hình được huấn luyện bằng thuật toán tối ưu Adam với các thông số trong Bảng 3.2.

Bảng 3.2: Cấu hình huấn luyện mô hình MLP

Thông số	**Giá trị**
Bộ tối ưu	Adam
Learning rate	0,000146
Batch size	256
Số epoch	300
Tỷ lệ Dropout	0,2
Hàm mất mát	Cross-Entropy
Số lớp đầu ra	10

Trong mỗi batch, dữ liệu được truyền qua mạng để tính logits và loss. Sau đó, thuật toán lan truyền ngược tính gradient của các tham số và Adam thực hiện bước cập nhật trọng số. Gradient cũ được xóa trước bước lan truyền ngược tiếp theo để tránh cộng dồn ngoài ý muốn.

Ở giai đoạn đánh giá, mô hình được chuyển sang chế độ `model.eval()` và không tính gradient. Các chỉ số được xem xét gồm accuracy, precision, recall, F1-score và ma trận nhầm lẫn. Khi tính trung bình loss theo batch, cần tính trọng số theo số mẫu trong từng batch để kết quả phản ánh đúng toàn bộ dữ liệu.

Chương 4

Kết quả và thảo luận

4.1 Kết quả huấn luyện

Mô hình MLP được đánh giá qua giá trị hàm mất mát và độ chính xác trên tập validation. Ở epoch thứ 300, validation loss đạt 1,6155 và validation accuracy đạt 84,45%. Kết quả cho thấy mô hình có khả năng nhận diện phần lớn các mẫu âm thanh trong tập đánh giá.

Tuy nhiên, chỉ số accuracy tổng thể chưa phản ánh đầy đủ hiệu quả trên từng thể loại. Vì vậy, cần phân tích thêm precision, recall, F1-score và ma trận nhầm lẫn để xác định sự khác biệt giữa các lớp.

4.2 Các chỉ số phân loại

Bảng 4.1 thể hiện các chỉ số precision, recall, F1-score và support của 10 lớp. Các lớp được ký hiệu từ 0 đến 9.

Bảng 4.1: Kết quả đánh giá phân loại trên 10 lớp âm nhạc

Nhãn	Precision	Recall	F1-score	Support
0	0,89	0,87	0,88	312
1	0,91	0,96	0,94	314
2	0,74	0,86	0,79	288
3	0,80	0,84	0,82	300
4	0,85	0,82	0,84	295
5	0,89	0,87	0,88	322
6	0,90	0,93	0,91	295
7	0,86	0,82	0,84	302
8	0,83	0,79	0,81	277
9	0,78	0,67	0,72	292
Macro avg	0,84	0,84	0,84	2.997
Weighted avg	0,85	0,84	0,84	2.997

Precision cho biết tỷ lệ dự đoán đúng trong số mẫu được mô hình gán vào một lớp;

recall cho biết tỷ lệ mẫu thực sự thuộc lớp đó được dự đoán đúng. F1-score là trung bình điều hòa giữa precision và recall:

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \frac{TP}{TP + FN}, \tag{4.1}$$

$$F_1 = \frac{2\,\text{Precision}\,\text{Recall}}{\text{Precision} + \text{Recall}}. \tag{4.2}$$

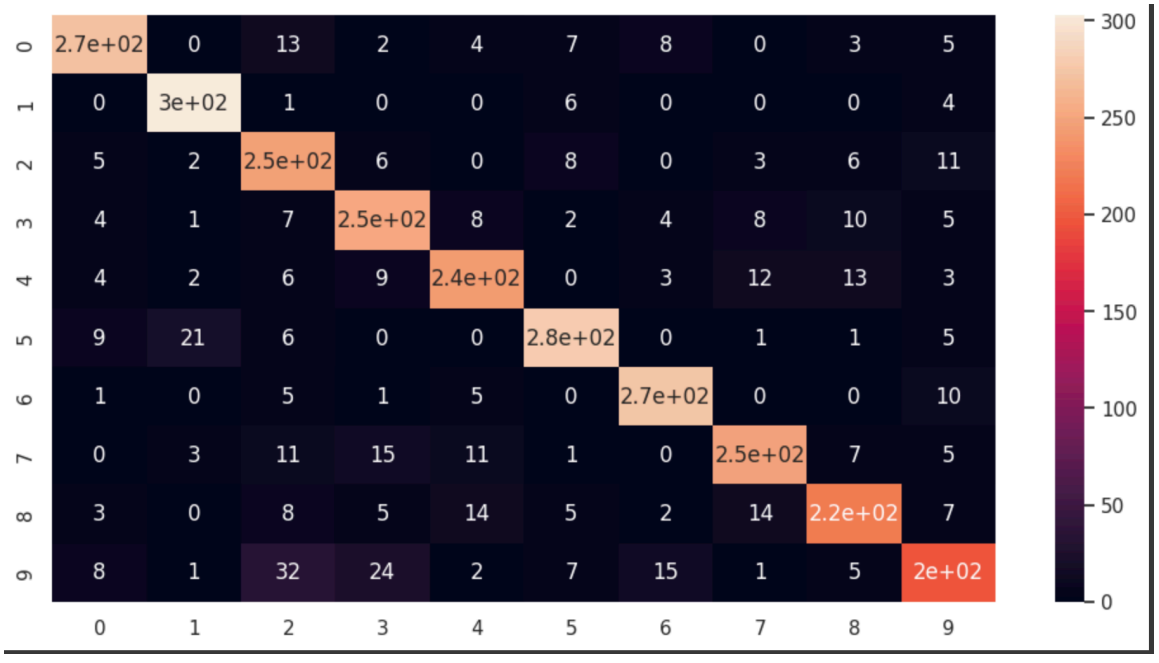
Trong đó, TP là số mẫu dương tính thật, FP là số mẫu dương tính giả và FN là số mẫu âm tính giả khi xét một lớp theo cách tiếp cận một-lớp-so-với-phần-còn-lại. Support là số mẫu thực tế thuộc từng lớp. Macro average là trung bình không trọng số giữa các lớp; weighted average là trung bình có trọng số theo support.

Theo Bảng 4.1, lớp 1 đạt F1-score cao nhất với giá trị 0,94, trong khi lớp 9 có F1-score thấp nhất, bằng 0,72, và recall 0,67. Điều này cho thấy khả năng phân loại chưa đồng đều giữa các lớp. Khi liên hệ chỉ số lớp với tên thể loại, cần sử dụng đúng bảng mã hóa nhãn đã áp dụng trong quá trình huấn luyện.

Độ chính xác hiển thị dưới dạng 0,84 trong kết quả phân loại phù hợp với mức accuracy khoảng 84%. Sự khác biệt nhỏ giữa các cách hiển thị có thể đến từ việc làm tròn và cách tổng hợp chỉ số.

4.3 Ma trận nhầm lẫn

Ma trận nhầm lẫn (confusion matrix) thể hiện số lượng dự đoán cho từng cặp nhãn thực tế và nhãn dự đoán. Các giá trị trên đường chéo chính đại diện cho những mẫu được phân loại đúng; các ô ngoài đường chéo thể hiện các trường hợp bị nhầm giữa những lớp khác nhau.



Hình 4.1: Ma trận nhầm lẫn của mô hình MLP

Phần lớn giá trị tập trung trên đường chéo chính, phù hợp với kết quả accuracy khoảng 84%. Tuy nhiên, vẫn có các trường hợp dự đoán sai giữa những lớp có đặc điểm âm thanh tương đồng. Để phân tích sâu hơn, có thể kiểm tra các đoạn nhạc bị nhầm và so sánh phân bố đặc trưng của chúng với các mẫu được nhận diện chính xác.

4.4 Thảo luận và hạn chế

4.4.1 Sự phụ thuộc giữa các đoạn nhạc

Việc chia một bản thu thành nhiều đoạn 3 giây làm tăng số mẫu nhưng không tạo ra các bản thu độc lập. Nếu những đoạn thuộc cùng bản nhạc xuất hiện ở cả tập huấn luyện và tập đánh giá, mô hình có thể tận dụng những đặc điểm riêng của bản thu thay vì học các đặc điểm tổng quát của thể loại. Vì vậy, chia dữ liệu theo bản thu gốc là một bước quan trọng để kết quả đánh giá đáng tin cậy hơn.

4.4.2 Số lượng mẫu đánh giá

Số mẫu dự kiến sau phân đoạn là 10.000 khi 1.000 bản nhạc đều tạo đủ 10 đoạn ngắn. Kết quả phân loại sử dụng 2.997 mẫu đánh giá. Hai con số này thể hiện hai phạm vi khác nhau: số mẫu có thể tạo ra từ toàn bộ dữ liệu và số mẫu thuộc tập được sử dụng để tính các chỉ số. Không thể suy ra số lượng tệp lỗi hoặc mẫu bị loại chỉ từ hai giá trị này.

4.4.3 Giới hạn của đặc trưng thống kê

Việc biểu diễn đoạn nhạc bằng trung bình và phương sai giúp giảm kích thước dữ liệu nhưng làm mất thông tin về thứ tự thời gian. Vì vậy, những đặc điểm về nhịp điệu, sự chuyển tiếp giữa các đoạn và cấu trúc thời gian dài không được mô tả đầy đủ. MLP cũng không khai thác trực tiếp các cấu trúc cục bộ theo thời gian và tần số như những mô hình nhận đầu vào là spectrogram.

4.4.4 Hướng cải tiến

Một số hướng phát triển có thể được xem xét gồm lựa chọn đặc trưng phù hợp hơn, tối ưu số nơ-ron và tỷ lệ Dropout, sử dụng cách chia dữ liệu theo bản thu gốc và đánh giá trên tập test độc lập. Ngoài ra, có thể so sánh MLP trên vector đặc trưng với CNN trên ảnh Mel spectrogram trong cùng điều kiện thực nghiệm để đánh giá ảnh hưởng của phương pháp biểu diễn tín hiệu.

4.5 Kết luận

Bài toán phân loại thể loại âm nhạc có thể được giải quyết thông qua quy trình trích xuất các đặc trưng xử lý tín hiệu kết hợp mạng nơ-ron truyền thẳng MLP. Các nhóm đặc

trưng như RMS, ZCR, spectral centroid, spectral bandwidth, spectral roll-off, chroma và MFCC cung cấp thông tin bổ trợ về năng lượng, phổ và âm sắc của tín hiệu.

Kết quả đánh giá cho thấy mô hình có khả năng phân loại 10 lớp âm nhạc với độ chính xác khoảng 84%. Tuy nhiên, chênh lệch precision, recall và F1-score giữa các lớp cho thấy vẫn còn khả năng cải thiện. Việc kiểm soát rò rỉ dữ liệu, lựa chọn đặc trưng và đánh giá độc lập là những yếu tố quan trọng để nâng cao độ tin cậy của hệ thống.